
Cartographier l'influence déclarée des lobbies sur le travail législatif

Ce que contient le projet, comment il a été construit,
et ce qu'il faut en retenir

Projet évalué du cours **Python pour la data science**
ENSAE 2A — CSC_4CS08_AE

Trois sources officielles croisées pour une seule question : la présence déclarée de lobbies sur un texte de loi laisse-t-elle une trace observable dans le travail et les votes des députés ? Ce document raconte le projet de bout en bout — les données, la méthode, les erreurs commises et corrigées, les résultats, et ce qu'il reste à faire. Il n'est pas le rendu : le rendu est le dépôt GitHub et son notebook. Il est là pour que tu saches exactement ce que tu rends.

Table des matières

1	En une page	2
2	Le sujet, et pourquoi il tient debout	3
2.1	La question posée	3
2.2	Les quatre textes retenus	3
3	Les données	4
3.1	Ce qui a été téléchargé	4
3.2	Les contrôles de qualité	4
4	Le problème central : aucune clé commune	6
4.1	Premier rapprochement : un scrutin et son dossier	6
4.2	Second rapprochement : une activité de lobbying et un texte	7
4.3	L’audit manuel : le chiffre qui compte	8
4.4	Un contre-exemple utile : quand la source fournit la clé	9
5	Construire une variable qui n’existe pas dans les données	10
5.1	Le problème	10
5.2	Le test placebo	10
6	Les résultats	11
6.1	Le vote final : un échec informatif	11
6.2	La dissidence sur les amendements	11
6.3	L’adoption des amendements, et ce que le placebo révèle	13
6.4	Le résultat le mieux identifié : les intérêts déclarés	13
7	Robustesse : ce qui se passe quand on change les choix arbitraires	16
7.1	La largeur de la fenêtre temporelle	16
7.2	La façon de mesurer	16
7.3	Le déterminisme	17
8	Un détour qui vaut le coup : les déports	18
9	Ce que le projet ne dit pas	19
10	L’organisation du code	19
10.1	Les commandes utiles	20
11	Préparer la soutenance	20
12	Ce qu’il te reste à faire	20

1 En une page

L'essentiel

La question. Est-ce qu'on voit, dans les amendements et les votes des députés, la trace des lobbies qui déclarent avoir travaillé sur un texte de loi ?

Les données. Environ **700 Mo**, quatre producteurs publics, aucune authentification : **113 075** activités de lobbying déclarées à la HATVP, **1 273 091** votes nominatifs de députés, **126 392** amendements, **11 438** intérêts déclarés par les députés, et la population de **34 955** communes pour mesurer la ruralité des circonscriptions.

La difficulté. Les trois bases n'ont *aucune clé commune*. Le répertoire des lobbies ne cite jamais de numéro de texte, ne donne pas de date précise, et ne nomme jamais le député approché. Tout le projet consiste à construire ce lien — et surtout à *mesurer à quel point il est faux*.

Les résultats.

1. Sur le **vote final**, la discipline de groupe explique tout : la règle « chacun vote comme son bloc » se trompe sur **3 votes sur 547** pour la loi agricole. Il n'y a rien de plus à expliquer à ce niveau.
2. Sur les **votes d'amendements**, où 4,3 % des positions s'écartent du groupe, la proximité avec les demandes des lobbies va dans le sens attendu mais **n'est pas significative** ($p \approx 0,08$), et le reste pour toutes les variantes testées.
3. Sur l'**adoption des amendements**, aucun effet non plus — mais le test témoin, lui, est significatif, ce qui apprend quelque chose sur la mesure.
4. Le seul résultat **bien identifié** ne concerne pas les lobbies mais les députés : déclarer un intérêt privé dans le secteur d'un texte multiplie par **1,7 à 3,0** la probabilité d'y déposer un amendement.

Ce qui fait la valeur du projet. Pas les résultats, qui sont pour l'essentiel négatifs. Le travail de rapprochement des bases, et sa *mesure* : 99,5 % de précision sur un rattachement interne à l'Assemblée, 100 % sur 20 paires relues à la main pour le ciblage des lobbies — contre 6 % pour la règle qu'on avait écrite d'abord. Le résultat méthodologique le plus solide est négatif : *une règle de rapprochement plausible peut être fausse neuf fois sur dix, et seule une relecture manuelle le révèle*.

Où est quoi

Chemin	Ce que c'est
<code>notebooks/rapport.ipynb</code>	Le rendu. Le rapport académique, 92 cellules, s'exécute en moins d'une minute sans erreur.
<code>src/lobbynamics/</code>	Le code, neuf modules, un par étape du raisonnement.
<code>docs/methode.md</code>	Le détail méthodologique et toutes les limites.
<code>docs/sources.md</code>	Provenance, licences, pièges de chaque source.
<code>docs/journal.md</code>	Journal de bord : décisions, erreurs, prochaines étapes.
<code>data/raw/</code>	Les 700 Mo de sources brutes (hors Git, retéléchargeables).
<code>reports/figures/</code>	Les 18 figures.
<code>tests/</code>	58 tests.

Tout se relance par une commande : `make pipeline`.

2 Le sujet, et pourquoi il tient debout

2.1 La question posée

Le lobbying parlementaire est documenté par la presse mais rarement mesuré. Depuis 2017, la France dispose pourtant d'un **répertoire des représentants d'intérêts** : toute organisation qui cherche à influencer une décision publique doit s'y déclarer et décrire ses actions. En parallèle, l'Assemblée nationale publie en open data l'intégralité de ses scrutins nominatifs et de ses amendements.

L'idée du projet est de croiser les deux. Pas pour « prouver la corruption » — ce serait indéfendable avec ces données, et le dire clairement fait partie du travail — mais pour **cartographier une influence déclarée** : est-ce que la présence affichée de lobbies d'un secteur sur un texte se voit dans le contenu des amendements et le sens des votes, une fois qu'on tient compte de l'appartenance politique ?

2.2 Les quatre textes retenus

Couvrir toute l'Assemblée n'aurait aucun sens. On s'est restreint à quatre textes de la XVII^e législature, choisis parce que le lobbying y est documenté et les volumes suffisants.

Clé	Texte	Scrutins	Amend.	Lobbies
agriculture	Loi d'urgence pour la souveraineté agricole	422	1 592	29
defense	Actualisation de la programmation militaire	292	572	14
fraudes	Lutte contre les fraudes sociales et fiscales	262	747	165
logement	Mobilisation de l'habitat existant	23	68	0

La dernière colonne compte les activités de lobbying qui *nomment* le texte. Le quatrième texte en a zéro, alors que 419 activités lui sont thématiquement proches : il sert de **cas témoin** et n'entre pas dans la modélisation. On y revient section 4.2, c'est l'argument le plus économique du projet.

Vocabulaire : trois mots qui reviennent partout

Scrutin — un vote de l'Assemblée, identifié par un numéro. Un même texte de loi donne lieu à des centaines de scrutins (un par amendement mis aux voix, plus le vote sur l'ensemble).

Dossier législatif — le « dossier » d'un texte de loi dans la nomenclature de l'Assemblée. C'est l'identifiant qu'on cherche à retrouver partout.

Activité (au sens HATVP) — une action de lobbying déclarée par une organisation : un objet en texte libre, un domaine, une année. C'est l'unité de base du répertoire.

3 Les données

3.1 Ce qui a été téléchargé

Source	Volume	Ce qu'on en tire
Répertoire HATVP des représentants d'intérêts	139 Mo	4 094 organisations, 113 075 activités déclarées : objet, domaine, type de décideur visé
Déclarations des responsables publics (HATVP)	83 Mo	2 570 déclarations de députés, 11 438 intérêts : anciens employeurs, participations, bénévolat
Scrutins publics, Assemblée	26 Mo	8 455 scrutins, 1 273 091 votes nominatifs
Amendements, Assemblée	304 Mo	126 392 amendements avec exposé des motifs
Dossiers législatifs	11 Mo	2 971 dossiers, titres et fenêtres de débat
Acteurs, mandats, organes	14 Mo	649 députés, groupes, commissions, <i>et le lien vers leur fiche HATVP</i>
API Géo (Etalab)	4 Mo	34 955 communes : population et surface, pour mesurer la ruralité

Tout est public et sans clé d'API. Un **manifeste** est écrit à chaque collecte (`data/raw/_manifeste.json`) : il enregistre pour chaque fichier son URL, sa taille, une empreinte SHA-256 et l'horodatage. C'est lui qui permet de dire *quelle version* des données a produit les résultats — une source open data change sans prévenir.

Trois pièges rencontrés, qui coûtent une demi-journée chacun

- L'URL officielle des amendements est `amendements_div_legis`, pas `amendements_legis` : la seconde renvoie une erreur 404 silencieuse.
- `liste.csv` de la HATVP n'est *pas* le répertoire des lobbies : c'est l'index des déclarations des élus. Les deux sont régulièrement confondus.
- Le JSON de l'Assemblée est une conversion automatique de XML. Un champ absent peut valoir `null`, `{"@xsi:nil": "true"}` ou `{"#text": "..."} ; une liste d'un seul élément devient un dictionnaire. Deux fonctions du code (_txt et _liste) n'existent que pour absorber ça, et sont couvertes par des tests.`

3.2 Les contrôles de qualité

Une erreur de lecture de fichier produit une exception, qu'on voit tout de suite. Une erreur de *données* produit un tableau plausible et faux, qu'on ne voit jamais. Le module `quality.py` écrit donc noir sur blanc ce qu'on attend des tables et vérifie que c'est vrai : identifiants uniques, intégrité entre tables, cohérence des décomptes de votes, plages de dates. **24 contrôles**, tous au vert aujourd'hui.

Une première version en signalait trois en rouge. Les trois se sont révélées être des **régularités explicables** — et c'est la raison pour laquelle ce sont devenus des contrôles précis plutôt que des seuils génériques :

Anomalie apparente	Explication trouvée
44,5 % des amendements sans « sort »	un amendement n'a de sort que s'il a été <i>discuté</i> : la relation est exacte, pas approximative
1,1 % des amendements sans auteur	ce sont exactement les amendements du Gouvernement , qui n'a pas d'auteur député
12 scrutins pointant vers un dossier introuvable	leurs identifiants commencent tous par <code>DLR5L16</code> : des textes entamés sous la législature <i>précédente</i>

Quatre lignes résistaient encore à la deuxième explication : des amendements à l'état « effacé », dont l'auteur a été retiré en même temps que le contenu. Quatre sur 126 392 — mais quatre lignes inexpliquées suffisent à faire douter du reste, donc elles sont tracées et exclues explicitement.

4 Le problème central : aucune clé commune

C'est le cœur du projet, et c'est ce que le correcteur regardera.

	Unité	Identifiant du texte	Date
Scrutins	un vote	présent une fois sur trois	au jour
Amendements	un amendement	toujours présent	au jour
Répertoire HATVP	une activité	aucun — du texte libre	à l'année

Le répertoire ne dit pas « j'ai travaillé sur le dossier DLR5L17N54085 ». Il dit :

« Défendre les loups dans le cadre de la loi d'urgence agricole »

Relier les deux est une **inférence**, pas une jointure. La bonne question n'est donc pas « comment faire le lien » mais « quelle est la probabilité que ce lien soit faux ».

4.1 Premier rapprochement : un scrutin et son dossier

Sur 8 455 scrutins, **5 826** n'ont aucun lien explicite vers leur dossier. Mais leur titre nomme le texte :

*« l'amendement n° 190 de M. Golliot après l'article 2 de la **proposition de loi visant à la nationalisation d'ArcelorMittal France** (première lecture). »*

On extrait la dénomination, on la compare aux titres des 2 971 dossiers par similarité de chaînes, et — c'est l'étape qui fait tout — on **arbitre par la date**.

Comment la précision est passée de 95,7 % à 99,5 %

La première version s'arrêtait à la similarité de titre et plafonnait à 95,7 %. En relisant les erreurs une par une, le motif saute aux yeux : **l'Assemblée ouvre un dossier distinct par lecture**. « Nationalisation d'ArcelorMittal France » existe *deux fois* dans la base. Un score de similarité de 100 ne départage alors rien.

En gardant tous les candidats à moins de 3 points du meilleur, puis en retenant celui dont la fenêtre d'activité parlementaire est la plus proche de la date du scrutin, la précision passe à **99,5 %**.

Le point méthodologique important : ce taux d'erreur est **mesuré, pas estimé**. Les 2 608 scrutins qui portent *déjà* un lien explicite forment une vérité terrain gratuite. On leur applique quand même la méthode approximative et on compare.

Bilan : **90,7 %** des scrutins rattachés (2 629 par lien déclaré, 5 041 par similarité). Les 9,3 % restants sont des titres qui ne nomment aucun texte (« l'ensemble du texte »).




Figure 1: La marche entre les seuils 75 et 80 est franche : en dessous, on rattache des textes seulement voisins. Le seuil retenu (88) coûte un sixième des scrutins, et c’est un coût assumé et chiffré plutôt qu’un sixième de lignes fausses.

4.2 Second rapprochement : une activité de lobbying et un texte

Là, aucune vérité terrain n’existe. Il faut relire à la main.

Première tentative. Règle intuitive : secteur de l’organisation compatible, domaine d’intervention compatible, mot-clé du texte présent dans l’objet déclaré, et exercice recouvrant la fenêtre de débat. Résultat : 904 activités retenues pour la loi agricole.

La règle était fautive neuf fois sur dix

Un échantillon de 60 paires a été relu une à une. Sur les 25 paires retenues et tranchables, **4 étaient justes** — une précision d’environ **16 %**.

Les faux positifs viennent presque tous d’un mot-clé trop général attrapé hors contexte. Exemple réel, retenu pour la loi agricole parce que le mot « filière » y figure :

« Contribuer aux réflexions des pouvoirs publics sur l’évolution du cadre général des filières de Responsabilité Élargie du Producteur »

Une variable d’exposition construite là-dessus aurait été, pour l’essentiel, du bruit.

Deuxième tentative, retenue. Deux niveaux explicites, et on ne mélange plus :

Niveau	Règle	Usage
1	l’objet déclaré nomme le texte : intitulé officiel ou abréviation d’usage (« LPM », « PJJ fraude », « loi d’urgence agricole »), en sous-chaîne exacte	la variable d’analyse
2	voisinage thématique — l’ancienne règle	décrire l’écosystème, jamais prouver

Pourquoi aucune « similarité approximative » au niveau 1

Une version intermédiaire comparait le titre du texte à l’objet déclaré avec un score de similarité partielle (`partial_token_set_ratio`). Elle retenait **11 170 activités sur 11 501**, dont des




Figure 2: Exiger que le texte soit nommé divise le volume retenu par vingt à cinquante. Noter le texte **logement** : 419 activités thématiquement proches, **zéro** qui le nomme.

déclarations sur le budget de la sécurité sociale pour la loi agricole.

C'est le comportement normal de ce score : il renvoie 100 dès que les mots de la référence apparaissent quelque part dans la cible, même dispersés. **Le flou est le bon outil pour comparer deux titres** (le rapprochement précédent). **C'est le mauvais outil pour chercher un titre dans un paragraphe.**

Le même piège s'est reproduit plus tard sur une autre source — il y rattachait tout à « Allocution du Président d'âge » avec un score de 100. Il est maintenant couvert par un test automatique, pour qu'il ne se reproduise pas une troisième fois.

4.3 L'audit manuel : le chiffre qui compte

60 paires tirées au sort, 20 par niveau, relues une à une. Les cas plausibles mais invérifiables sont annotés « incertain » et **exclus** du calcul : les ranger d'un côté ou de l'autre fabriquerait le résultat.

Niveau	Relues	Vrais ciblage	Incertains	Précision
1 — le texte est nommé	20	20	0	100 %
2 — voisinage thématique	20	1	4	6 %
0 — écartées	20	0	0	— (aucun oubli)

Sur l'échantillon, le niveau 1 a un **rappel de 95 %** : une seule activité réellement ciblante lui a échappé, parce qu'elle écrivait « PJA Agricole », forme absente de la liste d'abréviations. L'abréviation a été ajoutée, ce qui a capturé trois activités supplémentaires, toutes vérifiées et correctes. *Cette itération est documentée plutôt que masquée* : le seuil n'a pas été réglé sur le résultat final, une erreur identifiée a été corrigée.

À retenir pour la soutenance

L'échantillon est **stratifié**, pas aléatoire simple : on a tiré 20 paires par niveau pour pouvoir juger chaque niveau. Ces précisions valent donc *par strate* et ne s'extrapolent pas en un taux global. Si on te demande « quelle est la précision globale de votre matching ? », la bonne réponse

est : « la question n’a pas de sens telle quelle, nous mesurons une précision par niveau, et voici pourquoi ».

4.4 Un contre-exemple utile : quand la source fournit la clé

Tout n’est pas du rapprochement approximatif. Chaque acteur de l’open data de l’Assemblée porte un champ `uri_hatvp` qui pointe *exactement* sur sa page nominative à la HATVP. **88 %** des députés sont appariés par cette clé exacte, sans aucune heuristique (les 12 % restants n’ont pas de déclaration publiée à la date de collecte).

La leçon tient en une phrase, et elle vaut au-delà de ce projet : **chercher la clé fournie par la source avant d’inventer la sienne.**

5 Construire une variable qui n'existe pas dans les données

5.1 Le problème

Le répertoire HATVP dit « j'ai contacté des députés ». Il ne dit **jamais** lequel. Une exposition individuelle au lobbying ne peut donc pas être *lue* dans les données : elle doit être *construite*.

La méthode retenue. Pour chaque texte, on apprend un espace TF-IDF commun sur l'union de deux corpus — les exposés des motifs des amendements, et les objets déclarés des lobbies qui nomment le texte — puis on calcule les similarités cosinus.

TF-IDF et cosinus, en deux phrases

Le **TF-IDF** transforme un texte en vecteur de nombres : chaque mot reçoit un poids d'autant plus fort qu'il est fréquent dans ce texte et rare dans les autres. Le **cosinus** entre deux vecteurs mesure alors à quel point deux textes emploient le même vocabulaire rare — 0 s'ils n'ont rien en commun, 1 s'ils sont identiques.

Ce que cette mesure n'est pas

Ce n'est **pas** une mesure de contact. C'est une mesure de **convergence de discours**, et trois lectures sont possibles, que les données ne permettent pas de départager :

1. le lobby a influencé la rédaction de l'amendement ;
2. le lobby a ciblé un député *déjà convaincu* — c'est la lecture la plus fréquente dans la littérature sur le lobbying, et elle suffit à produire la corrélation sans aucune influence ;
3. les deux emploient le vocabulaire technique du secteur, sans lien.

C'est pourquoi le mot « influence » n'apparaît jamais sans « déclarée » dans les titres de figures.

5.2 Le test placebo

Rien ne garantit a priori que la mesure capte du *sectoriel* plutôt que du *style*. On calcule donc, pour chaque amendement, une **seconde** proximité : celle aux demandes déclarées des lobbies d'un *autre* texte de l'étude. Si les deux se valaient, la mesure ne capterait que « cet amendement est écrit en français administratif dense », et il faudrait tout jeter.

Détail technique qui a son importance : les deux corpus sont ramenés à la **même taille** par tirage à graine fixe, parce que le maximum d'une similarité sur N documents croît mécaniquement avec N . Sans cette correction, le témoin « gagnait » sur la défense simplement parce que son corpus comptait 165 objets contre 14.

La proximité mesurée est bien sectorielle, pas stylistique




Figure 3: La proximité réelle domine le témoin sur les trois textes. La mesure capte bien quelque chose de sectoriel — ce qui ne dit toujours rien d’une influence.

6 Les résultats

Quatre régressions logistiques, dans un ordre qui est un argument et pas un catalogue.

Lire une régression logistique

Elle estime la probabilité d’un événement binaire (voter « pour », être adopté...) en fonction de plusieurs variables. On lit surtout deux choses : l’**odds ratio** (à droite de 1 : l’événement devient plus probable ; à gauche : moins) et la **p-value** (en dessous de 0,05, on considère par convention que l’effet n’est pas dû au hasard).

Ici tous les écarts-types sont **groupés par député** : un même député apparaît dans des centaines de scrutins, ses erreurs sont corrélées, et des écarts-types classiques seraient artificiellement petits — donc des p-values artificiellement bonnes.

6.1 Le vote final : un échec informatif

La règle « chaque député vote comme la majorité de son bloc » se trompe sur :

Texte	Votes exprimés	Erreurs	Exactitude
agriculture	547	3	99,5 %
defense	562	37	93,4 %
fraudes	557	3	99,5 %

Conséquence directe : un modèle logistique avec effets fixes de bloc **ne converge pas**, parce que cinq blocs sur sept votent à 0 % ou 100 %. Le code le détecte et le dit, au lieu d’afficher des écarts-types astronomiques. *Ce n’est pas un bug à contourner, c’est le résultat* : il n’y a plus de variance à expliquer à ce niveau. Il faut descendre d’un cran.

6.2 La dissidence sur les amendements

Sur les **970** scrutins d’amendements des trois textes, **4,3 %** des 89 472 votes s’écartent de la position majoritaire du groupe — et 74 % des députés dissident au moins une fois sur la loi agricole. Voilà la variance qu’on cherchait.

Effets marginaux moyens, en points de probabilité :




Figure 4: Le vote sur l'ensemble du texte se lit entièrement dans l'appartenance de bloc.




Figure 5: C'est dans les votes d'amendements que la discipline se fissure.

Variable	Effet	p
proximité lexicale avec les lobbies (+1 écart-type)	+0,34 pt	0,080
intérêt sectoriel déclaré	+0,72 pt	0,082
a déposé un amendement sur le texte	-1,09 pt	0,031
ruralité de la circonscription (+1 écart-type)	+0,00 pt	0,982
membre de la commission saisie au fond	-0,20 pt	0,494

Lecture. Les deux variables liées au lobbying vont dans le sens attendu mais **ne sont pas significatives** au seuil de 5 %. *On ne conclut pas à un effet.* Et il faut regarder l'ordre de grandeur : +0,34 point sur un taux de base de 4,3 %, soit environ 8 % de hausse relative, à comparer aux +5 à +8 points de l'appartenance de bloc.

Le seul effet net est négatif, et peu surprenant : un député qui dépose des amendements sur un texte dissidente *moins*. Déposer des amendements est plutôt un marqueur d'investissement dans la ligne de son groupe.

6.3 L'adoption des amendements, et ce que le placebo révèle

Changement d'unité d'observation : l'amendement lui-même. On ne garde que les **1 145** amendements *tranchés* (adoptés ou rejetés) — un amendement retiré ou tombé n'a pas été jugé sur son contenu.

Mesure	Odds ratio	IC 95 %	p
proximité aux lobbies du texte	1,01	[0,86 ; 1,20]	0,891
proximité aux lobbies d'un autre texte (témoin)	0,77	[0,62 ; 0,95]	0,015

Pourquoi ce résultat est le plus intéressant du projet

La proximité aux lobbies du texte n'a **aucun effet** sur l'adoption. En revanche le **témoin** est significativement *négatif* : un amendement dont le vocabulaire ressemble aux demandes d'un *autre* secteur a moins de chances d'être adopté.

Sans le placebo, on aurait conclu « pas d'effet » et on serait passé à côté de ce que la mesure capte réellement : **elle sépare les amendements dans le sujet de ceux qui en sortent**, et les amendements hors sujet sont rejetés. C'est rassurant sur le fonctionnement parlementaire, et instructif sur ce que mesure vraiment un cosinus TF-IDF.

Ce qui prédit réellement l'adoption reste l'appartenance politique : par rapport au centre, les odds d'adoption sont divisés par 3 à droite et par 15 à la gauche radicale.

6.4 Le résultat le mieux identifié : les intérêts déclarés

Jusqu'ici, toutes les mesures d'exposition reposaient sur une inférence. Il existe pourtant une information **déclarée par le député lui-même** et jamais inférée : ses intérêts privés (anciens employeurs, participations, fonctions de direction, bénévolat).

Encore faut-il la nettoyer. Première découverte : **51 % de doublons**. Un député qui dépose une déclaration initiale puis une déclaration modificative voit ses intérêts inchangés recopiés à l'identique. Les compter deux fois aurait gonflé mécaniquement les députés les plus actifs administrativement — exactement le contraire de ce qu'on cherche.




Figure 6: Le classement sectoriel repose sur un lexique court et lisible ; il ne rattache que 34 % des libellés, « autoentrepreneur » ou « SCI familiale » ne disant rien du secteur. C'est une limite, pas un détail.




Figure 7: Un député qui déclare un intérêt privé dans le secteur d'un texte a environ trois fois plus de chances d'y déposer un amendement ; un membre de la commission saisie au fond, quatorze fois plus.

Comment formuler ce résultat sans se tromper

C'est la seule relation du projet qui n'exige **aucune inférence** : les intérêts sont déclarés par le député lui-même, et le dépôt d'un amendement est un fait.

Mais ce n'est **pas** une mise en cause. Un ancien agriculteur qui siège en commission des affaires économiques et amende la loi agricole fait exactement ce pour quoi il a été élu. La frontière entre **spécialisation** et **conflit d'intérêts** n'est pas dans ces données : elle est dans le *sens* de l'amendement, que le TF-IDF ne voit pas.

C'est probablement la question que le correcteur posera. La réponse est celle-là.

7 Robustesse : ce qui se passe quand on change les choix arbitraires

Trois choix du projet n'ont aucune justification théorique et ont été faits à la main. Un résultat qui dépend d'un de ces choix n'est pas un résultat.

7.1 La largeur de la fenêtre temporelle

Le répertoire ne date les activités qu'à l'année. On considère donc qu'une activité peut concerner un texte si son exercice recouvre la fenêtre de débat, élargie de six mois — six mois étant un chiffre *choisi*, pas mesuré.




Figure 8: Le volume d'activités retenues passe de 184 à 256 selon la fenêtre, mais le coefficient reste entre 0,06 et 0,09 et n'atteint jamais le seuil de 5 %. Le non-résultat n'est pas un artefact de ce choix.

7.2 La façon de mesurer

Variante	Odds ratio	p	Conclusion
proximité = maximum	1,09	0,081	non significatif
proximité = moyenne des 5 plus proches	1,07	0,236	non significatif
intérêt = vocabulaire du texte	3,01	0,0003	significatif
intérêt = classement sectoriel	1,70	0,054	limite

Ce qui tempère le résultat de la section précédente

Les deux façons de repérer un intérêt sectoriel s'accordent à 93 % — mais sur une variable aussi rare, l'accord brut est trompeur : le **kappa de Cohen** vaut **0,45**, soit un accord seulement modéré.

L'effet reste positif et de même sens avec les deux mesures, mais son ampleur passe d'un odds ratio de **3,0** à **1,7**, et sa p-value de 0,0003 à 0,054.

La conclusion honnête est donc : *le sens de la relation est robuste, son ampleur ne l'est pas*.
Mieux vaut annoncer le bas de la fourchette.

7.3 Le déterminisme

Deux sources d'aléa existent dans le projet : le tirage de l'échantillon d'audit et le sous-échantillonnage du corpus placebo. Les deux sont à graine fixe — encore faut-il le vérifier, parce qu'une graine oubliée ne se voit jamais sur une seule exécution. Le pipeline recalcule donc trois tables deux fois de suite et compare leurs empreintes SHA-256. Les trois sont identiques.

8 Un détour qui vaut le coup : les déports

Un **déport** est la décision d'un député de ne pas prendre part à un vote en raison d'un intérêt personnel. C'est, dans tout le paysage de données exploré par ce projet, **le seul endroit où un député, un intérêt privé et un texte précis sont nommés ensemble**. Le répertoire HATVP ne nomme jamais le député approché ; les déclarations d'intérêts ne nomment aucun texte. Ici, les trois sont réunis.

Mais il y en a **59** depuis 2017, dont 9 pour la législature en cours. Aucune statistique n'est possible : c'est une source qualitative, et un **point de vérification** du reste de la chaîne — les scrutins étant nominatifs, un déport annoncé est contrôlable ligne à ligne.

Deux limites apparaissent immédiatement, et elles sont instructives :

- la plupart des déports visent **certains articles**, pas le texte entier ; on ne peut donc rien conclure au niveau du dossier, le député ayant le droit de voter sur tout le reste ;
- deux références (« Articles de loi ayant trait aux assurances... ») ne nomment aucun texte identifiable, et restent volontairement non rattachées — inventer un rattachement serait pire que l'absence.

Un seul déport est vérifiable au niveau du dossier : un député déclarant être « en disponibilité » d'un groupe industriel de défense, et se déportant de l'intégralité du projet de loi de programmation militaire. Sur les **292** scrutins du dossier postérieurs à ce déport, il n'apparaît dans le détail nominatif que pour **un seul vote** — celui sur l'ensemble du texte issu de la commission mixte paritaire.

Ce que les données disent, et où elles s'arrêtent

Elles disent : 291 scrutins sans position enregistrée, 1 vote exprimé. Elles ne disent **pas** si c'est un oubli, un changement de situation, ou une lecture du déport qui en exclut le vote final. Il n'y a aucune mise en cause à tirer de là.

Ce qu'il faut en retenir pour le projet est ailleurs : un engagement public **peut** être vérifié ligne à ligne dès lors que la source nomme à la fois la personne et le texte. C'est précisément ce qui manque au répertoire des lobbies, et c'est pour ça que tout le reste du projet repose sur des inférences.

9 Ce que le projet ne dit pas

Par ordre de gravité. C’est la section que le correcteur lira le plus attentivement, et c’est elle qui vaut des points.

1. **Le répertoire HATVP est autodéclaratif.** Une organisation qui ne déclare rien est invisible. Transparency International et l’Observatoire des multinationales contestent régulièrement l’exhaustivité du registre. On mesure le lobbying *déclaré*, qui est un sous-ensemble inconnu du lobbying réel.
2. **Pas de datation fine.** Une activité est rattachée à un exercice annuel ; la fenêtre de débat est élargie de six mois de part et d’autre, ce qui est arbitraire — mais testé (section précédente).
3. **Causalité : aucune.** La corrélation mesurée est compatible avec l’absence totale d’influence.
4. **Rappel faible au niveau 1.** Une organisation qui décrit son action sans nommer le texte est perdue. Le projet préfère 208 rattachements sûrs à 1 383 douteux, mais c’est un arbitrage, pas une vérité.
5. **La proximité TF-IDF est purement lexicale.** Elle ne voit pas que deux formulations opposées peuvent partager tout leur vocabulaire : un amendement qui *interdit* une substance et une demande de lobby qui la *réautorise* se ressemblent beaucoup pour un cosinus. C’est la limite la plus sérieuse du projet.
6. **Une seule législature.** La XVII^e est marquée par une fragmentation politique inhabituelle ; les taux de dissidence ne sont pas transposables.

10 L’organisation du code

Neuf modules, un par étape du raisonnement. Le notebook ne fait qu’appeler des fonctions : aucune logique n’y est écrite, ce qui est explicitement demandé par les consignes (« pas de copier-coller de cellule, préférez des fonctions »).

Module	Rôle
<code>config.py</code>	chemins, URL des sources, textes étudiés, nomenclatures
<code>collect.py</code>	téléchargement idempotent et manifeste de provenance
<code>parse_an.py</code>	mise à plat de l’open data Assemblée
<code>parse_hatvp.py</code>	mise à plat du répertoire et des déclarations HATVP
<code>matching.py</code>	rapprochement des bases et sa validation chiffrée
<code>features.py</code>	variables d’analyse, proximité lexicale, placebo
<code>models.py</code>	les quatre régressions
<code>quality.py</code>	24 contrôles de qualité des données
<code>robustesse.py</code>	sensibilité aux choix arbitraires, déterminisme
<code>viz.py</code>	les 18 figures
<code>pipeline.py</code>	orchestration : <code>python -m lobbymomics.pipeline</code>

10.1 Les commandes utiles

Commande	Effet
<code>make pipeline</code>	la chaîne complète, de l'URL aux figures
<code>make rapide</code>	tout sauf le téléchargement et la mise à plat (≈ 1 min)
<code>make tests</code>	les 58 tests
<code>make rapport</code>	exécute le notebook de bout en bout
<code>make qualite</code>	les contrôles de qualité seuls

Une **intégration continue** GitHub Actions lance les tests à chaque poussée, sur Python 3.11 et 3.12. Elle ne télécharge aucune donnée : une CI qui dépend de 700 Mo d'open data tombe en panne le jour où une source change d'URL, pour une raison qui n'a rien à voir avec le code.

11 Préparer la soutenance

Les questions probables, et ce qu'il faut répondre.

Question	Réponse
« Vous ne trouvez rien, alors ? »	Sur les lobbies, non, et c'est dit. Le projet mesure surtout le <i>prix du rapprochement</i> entre bases : 99,5 % de précision ici, 6 % pour une règle plausible qu'on a dû jeter. C'est ça le résultat.
« Pourquoi pas de régression sur le vote final ? »	Parce qu'elle ne converge pas : cinq blocs sur sept votent à 0 ou 100 %. Le modèle sépare parfaitement les données. On le montre, on l'explique, et on change de niveau d'observation.
« Comment savez-vous que votre matching est bon ? »	Deux façons : les 2 608 scrutins à lien explicite servent de vérité terrain gratuite ; et 60 paires HATVP ont été relues une à une, avec le détail des verdicts dans le dépôt.
« Pourquoi avoir choisi ces trois textes ? »	Lobbying documenté, volumes suffisants, et trois secteurs différents. Le quatrième texte est gardé comme témoin négatif.
« C'est quoi votre variable d'exposition, exactement ? »	Une convergence de vocabulaire, pas un contact. Le répertoire ne nomme jamais le député. On le dit dans chaque titre de figure.
« Et la causalité ? »	Aucune. Un lobby cible d'abord les députés déjà convaincus ; la corrélation serait la même sans aucune influence.
« Pourquoi un test placebo ? »	Pour vérifier que la mesure capte du sectoriel et pas du style. Et il a appris quelque chose : c'est le témoin qui est significatif, pas la vraie mesure.
« Votre projet est-il reproductible ? »	Une commande, un manifeste de provenance avec empreintes SHA-256, 58 tests, une CI, et une vérification que deux exécutions donnent exactement les mêmes nombres.

12 Ce qu'il te reste à faire

1. **Faire valider le sujet** par la chargée de TD (Yasmine Benjelloun, yasmine.benjelloun@polytechnique.edu). C'est explicitement exigé.
2. **T'inscrire sur le Google Sheet** de constitution des groupes (2 à 3 personnes).

3. **Créer le dépôt GitHub public** et y pousser *progressivement*. L'historique de version est noté : les dépôts constitués d'un seul envoi sont pénalisés. Le dépôt local contient déjà neuf commits thématiques pour démarrer.
4. **Confirmer les dates** de rendu et de soutenance : la page du cours affiche encore « XX décembre 2026 » et « XX janvier » au 2 octobre.
5. **Relire l'audit manuel** (`data/processed/audit_ciblage_a_annoter.csv`). Les 60 verdicts y sont, avec un commentaire pour chaque cas discutable. C'est ton nom qui sera dessus : si tu n'es pas d'accord avec un verdict, change-le, le pipeline recalcule les précisions automatiquement.
6. **Lire docs/methode.md** avant la soutenance : c'est la version longue de ce document, avec les impasses détaillées.

Les pistes si vous voulez aller plus loin

- **Les textes budgétaires** (projet de loi de finances, budget de la sécurité sociale), où le lobbying déclaré est de très loin le plus dense — et où le rattachement des scrutins est le plus difficile, donc le plus intéressant.
- **Un modèle de phrases** à la place du TF-IDF, pour capter l'opposition sémantique que le cosinus lexical ignore.
- **Le sens des amendements** : c'est le vrai chaînon manquant entre spécialisation et capture, et aujourd'hui personne ne le mesure proprement.